Baba
Mathieu
Info3

Rapport TP ML

1) Chargement et description des données

Dans ce TP, nous travaillons sur le dataset *titanic.csv* qui répertorie l'identité des différents passagers du Titanic et s'ils ont survécu ou non à la tragédie. Le dataset contient 891 observations et 16 variables, dont :

- **survived:** Indique si le passager a survécu (1) ou non (0).
- **pclass:** Représente la classe du billet (1ère, 2ème ou 3ème classe).
- **sex:** Indique le sexe du passager (homme ou femme).
- **age:** Âge du passager en années.
- **sibsp:** Nombre de frères, sœurs ou conjoint(e) présents à bord.
- **parch:** Nombre de parents ou enfants présents à bord.
- **fare:** Montant payé pour le billet.
- **embarked:** Code du port d'embarquement (C, Q ou S).
- **class:** Version textuelle de la classe du billet (First, Second, Third).
- **who:** Catégorie du passager selon âge et sexe (man, woman, child).
- **adult_male:** Indique si le passager est un homme adulte (True/False).
- **deck:** Pont du navire où se trouvait la cabine du passager.
- **embark_town:** Nom complet du port d'embarquement.
- **alive:** Version textuelle de la variable survived (yes/no).
- **alone:** Indique si le passager voyageait seul (True/False).

Ce dataset présente plusieurs problèmes pour l'entraînement d'un modèle, le premier étant la proportion de valeurs nulles présentes dans les features age, embarked, deck et embarked_town. Pour les features age, embarked et embarked_town, la proportion de valeurs nulles est assez minime donc ce n'est pas nécessaire de supprimer ces colonnes. Par contre, deck présente une proportion assez conséquente de valeurs nulles (688/891 valeurs NaN), il est donc nécessaire de la supprimer.

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 891 entries, 0 to 890
Data columns (total 16 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   Unnamed: 0   891 non-null    int64
 1   survived     891 non-null    int64
 2   pclass       891 non-null    int64
 3   sex          891 non-null    object
 4   age          714 non-null    float64
 5   sibsp        891 non-null    int64
 6   parch        891 non-null    int64
 7   fare         891 non-null    float64
 8   embarked     889 non-null    object
 9   class        891 non-null    object
 10  who          891 non-null    object
 11  adult_male   891 non-null    bool
 12  deck         203 non-null    object
 13  embark_town  889 non-null    object
 14  alive        891 non-null    object
 15  alone        891 non-null    bool
dtypes: bool(2), float64(2), int64(5), object(7)
memory usage: 99.3+ KB
```

Le deuxième problème est que d'autres features sont redondantes comme :

- **alive** est équivalente à **survived**
- **class** est équivalente à **pclass**
- **embark_town** est équivalente à **embarked**
- **Unnamed: 0** correspond à un index

	Unnamed: 0	survived	pclass	sex	age	sibsp	parch	fare	embarked	class	who	adult_male	deck	embark_town	alive	alone
0	0	0	3	male	22.0	1	0	7.2500	S	Third	man	True	NaN	Southampton	no	False
1	1	1	1	female	38.0	1	0	71.2833	C	First	woman	False	C	Cherbourg	yes	False
2	2	1	3	female	26.0	0	0	7.9250	S	Third	woman	False	NaN	Southampton	yes	True
3	3	1	1	female	35.0	1	0	53.1000	S	First	woman	False	C	Southampton	yes	False
4	4	0	3	male	35.0	0	0	8.0500	S	Third	man	True	NaN	Southampton	no	True

Pour ce TP, l'objectif sera de prédire la variable **survived**, indiquant selon certaines features si un passager aurait pu survivre ou non à la tragédie. On est donc sur un problème de **classification binaire**.

2) Exploration et visualisation

L'analyse de la variable survived montre que 62 % des passagers n'ont pas survécu, contre 38 % qui ont survécu. Ce déséquilibre est important car il indique que le jeu de données est dominé par les non-survivants.

Concernant le graphique des distributions, nous pouvons l'intérpreter comme suit:

1. Unnamed: 0

Cette variable est simplement un identifiant ou un index. Sa distribution uniforme confirme qu'elle n'apporte aucune information pertinente pour l'analyse ou la modélisation. Elle pourra être supprimée.

2. survived

On observe deux barres correspondant aux classes 0 (non-survivants) et 1 (survivants). La barre des non-survivants est plus haute, ce qui confirme le déséquilibre des classes déjà calculé (549 décès, 342 survivants). Cela montre que la variable cible est binaire et déséquilibrée.

3. pclass

La majorité des passagers se trouvent en 3e classe, suivis par la 1re et la 2e classe. Cette variable reflète le statut socio-économique.

4. age

La distribution est asymétrique (right-skewed) : la plupart des passagers ont entre 20 et 40 ans, avec quelques enfants et personnes âgées. Cela suggère que l'âge est une variable continue avec des valeurs extrêmes. Les enfants et les seniors pourraient avoir des comportements de survie différents.

5. sibsp

La majorité des passagers ont 0 ou 1 frère/sœur ou conjoint à bord. Peu de passagers voyagent avec de grandes fratries. Cela indique que la plupart des individus étaient seuls ou en couple.

6. parch

La plupart des passagers n'ont pas de parents ou enfants à bord (valeur 0). Quelques familles sont présentes, mais elles sont minoritaires. Cette variable, combinée à sibsp, permet de mesurer si un passager voyageait seul ou accompagné.

7. fare

La distribution est fortement asymétrique : la majorité des billets coûtent moins de 100, mais quelques billets très chers apparaissent comme outliers. Cela reflète la disparité socio-économique entre les passagers. Les valeurs extrêmes devront être traitées pour éviter qu'elles ne biaisent la modélisation.

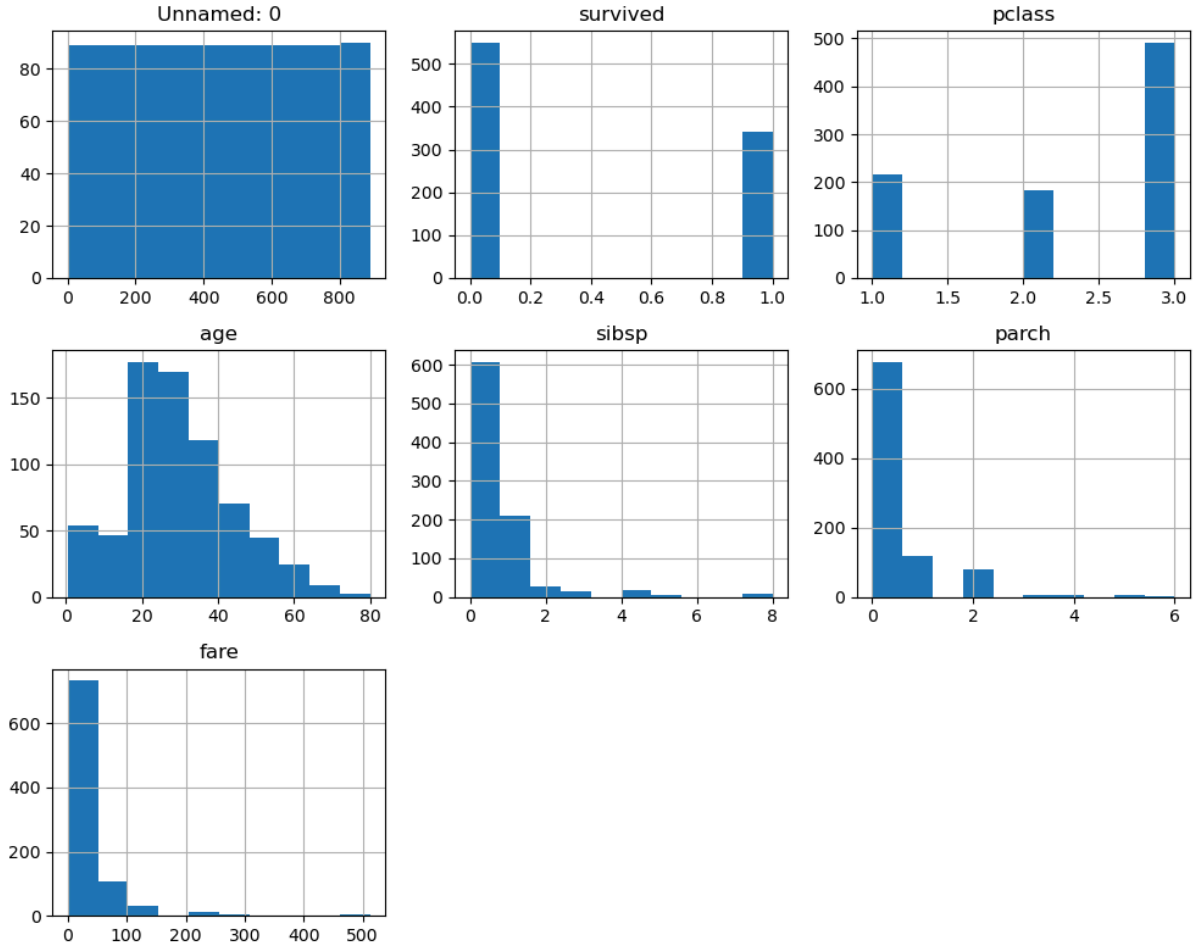

La visualisation des survivants par sexe montre une différence importante. D'une part, la majorité des hommes n'ont pas survécu, tandis que la majorité des femmes ont survécu. Ce résultat illustre la règle appliquée lors du naufrage, "Les femmes et les enfants d'abord". Le sexe apparaît donc comme une variable fortement discriminante pour la survie et sera probablement l'un des prédicteurs les plus importants dans les modèles.

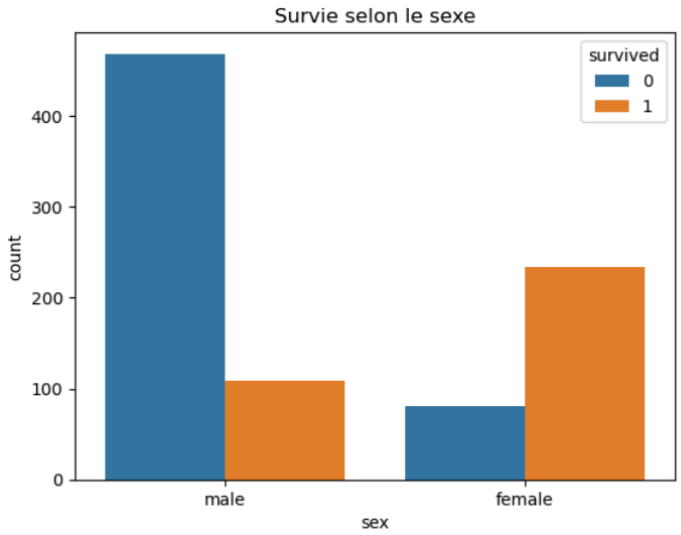

L'analyse par classe révèle que les passagers de 1re classe ont eu plus de chances de survie que ceux des autres classes. En 2e classe, les proportions de survivants et de non-survivants sont relativement équilibrées. En revanche, en 3e classe, la mortalité est très élevée. Cette tendance suggère que le statut socio-économique, représenté par la classe du billet, a joué un rôle déterminant dans l'accès aux canots de sauvetage et donc dans les chances de survie.

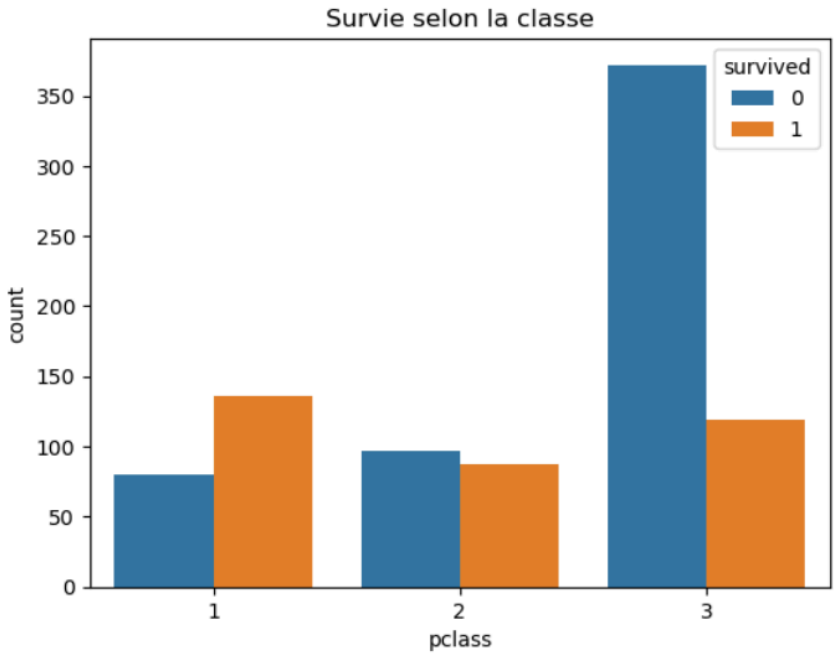

La matrice de corrélation met en évidence plusieurs relations intéressantes :

- La survie est négativement corrélée avec la classe (pclass) et avec le fait d'être un homme adulte (adult_male).
- Elle est positivement corrélée avec le prix du billet (fare), ce qui confirme que les passagers ayant payé des billets plus chers avaient davantage de chances de survivre.
- La variable alone est négativement corrélée avec la survie : voyager seul réduisait les chances de survie.
- Enfin, sibsp et parch sont fortement corrélés entre eux, ce qui traduit la présence de familles voyageant ensemble.

Ces corrélations permettent d'identifier les variables les plus pertinentes pour la modélisation, notamment sex, pclass, fare et alone.

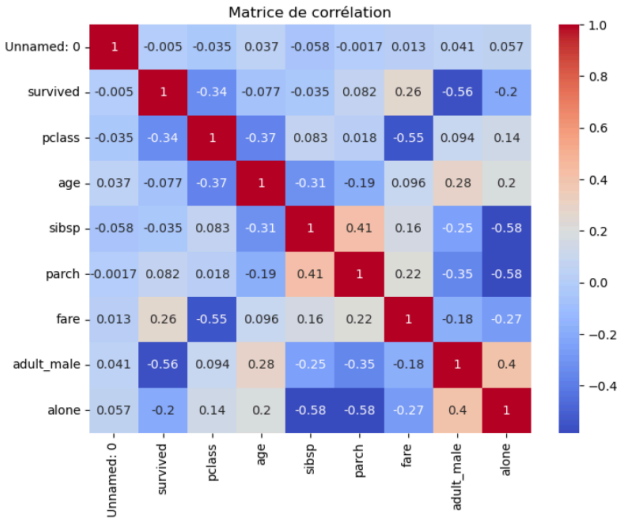

3) Traitement des valeurs manquantes

Le traitement des valeurs manquantes a permis d'améliorer la qualité du dataset avant la modélisation. Les variables présentant un trop grand nombre de valeurs manquantes, notamment deck (plus de 77 %), ont été supprimées afin d'éviter d'introduire du bruit dans le modèle. Deux stratégies d'imputation ont été testées : **l'imputation** par la **médiane** pour la variable **age**, méthode robuste face aux valeurs extrêmes, et **l'imputation** par **KNN**, qui exploite la similarité entre les observations pour estimer les valeurs manquantes. Les variables catégorielles présentant quelques valeurs manquantes ont été imputées par la modalité la plus fréquente afin de préserver la cohérence des catégories. Cette étape permet d'obtenir un dataset plus propre et adapté à la phase de modélisation.

4) Détection et traitement des outliers

La détection et le traitement des valeurs aberrantes ont été réalisés afin d'améliorer la robustesse du modèle d'apprentissage. Le premier graphique, intitulé Détection visuelle des outliers, met en évidence la présence de nombreuses valeurs extrêmes, notamment dans la variable fare, où certains billets dépassent largement les bornes usuelles, ainsi que quelques cas isolés dans sibsp, parch et age_median. Cette étape de diagnostic est essentielle car les outliers peuvent biaiser les statistiques descriptives et perturber les algorithmes de machine learning, en particulier ceux sensibles aux valeurs extrêmes. Pour les identifier, la méthode de l'IQR (Interquartile Range) a été utilisée, car elle est adaptée aux distributions asymétriques et moins influencée par les valeurs extrêmes que la règle des ±3 écarts-types. Le second graphique, Outliers après traitement, illustre la situation après application

d'une stratégie de capping (winsorisation), qui consiste à limiter les valeurs extrêmes aux bornes calculées plutôt que de supprimer des observations. On constate que la dispersion des données est mieux maîtrisée, tout en conservant la taille du dataset et donc l'information disponible. L'interprétation générale est que cette approche permet de réduire l'impact des anomalies tout en préservant la représentativité des données, ce qui contribue à améliorer la stabilité et la performance potentielle du modèle lors de l'apprentissage.

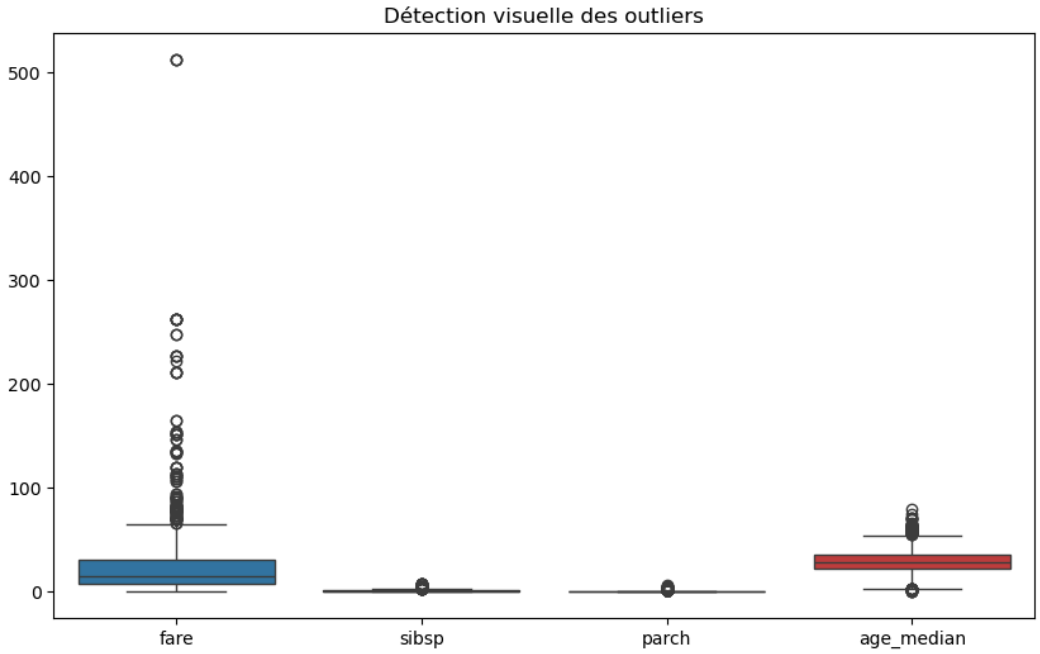

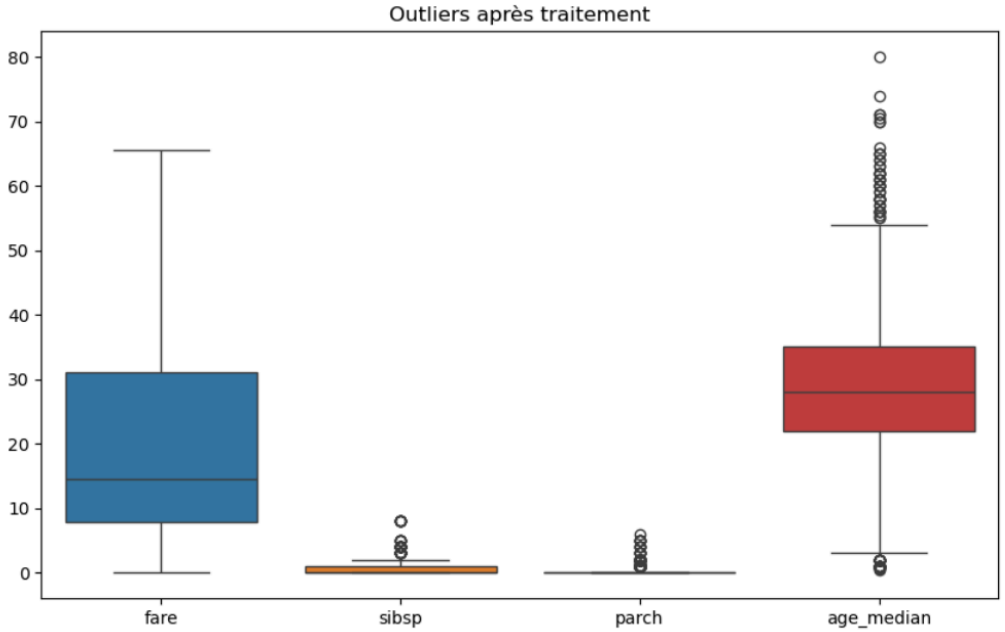

5) Prétraitement et encodage

Premièrement, **les variables catégorielles** ont été transformées en **valeurs numériques** afin de pouvoir être utilisées par les modèles de machine learning. La méthode **One-Hot Encoding** a été utilisée car les catégories n'ont pas d'ordre logique (par exemple le sexe ou le port d'embarquement). Cette méthode crée une colonne binaire pour chaque catégorie et évite d'imposer un ordre artificiel entre les valeurs.

Deuxièmement, **les variables numériques** ont été mises à la même échelle à l'aide de la **standardisation**. Cette méthode est utilisée car certaines variables comme l'âge et le prix du billet ont des valeurs très différentes. La standardisation permet d'éviter qu'une variable domine les autres et améliore la performance des modèles d'apprentissage automatique.

6) Séparation features et target

La matrice **X** contient les variables explicatives utilisées pour prédire la survie des passagers, tandis que le vecteur **y** correspond à la variable cible **survived**. Cette séparation est nécessaire car les modèles de machine learning apprennent à partir des features pour prédire la valeur cible.

Les données ont ensuite été divisées en un ensemble **d'entraînement** et un ensemble de **test** avec une répartition de 80 % pour l'entraînement et 20 % pour le test. L'ensemble d'entraînement sert à apprendre le modèle, tandis que l'ensemble de test permet d'évaluer sa performance sur des données qu'il n'a jamais vues. Cette méthode permet d'obtenir une estimation fiable des performances du modèle et d'éviter le surapprentissage.

7) Modélisation

Deux modèles de classification ont été entraînés afin de prédire la survie des passagers. Une régression logistique a été utilisée car elle est simple à interpréter et adaptée aux problèmes de classification binaire. Un modèle Random Forest a également été entraîné car il est plus puissant et permet d'améliorer la précision en combinant plusieurs arbres de décision. Afin d'optimiser les performances du modèle Random Forest, une recherche d'hyperparamètres a été effectuée à l'aide de GridSearchCV, permettant de tester différentes configurations du nombre d'arbres, de la profondeur maximale et du nombre minimum d'échantillons par feuille. Cette optimisation permet de sélectionner automatiquement la meilleure configuration du modèle en fonction du score d'exactitude.

Le modèle Random Forest optimisé a obtenu un score d'accuracy d'environ 82,7 % sur la validation croisée. Les meilleurs paramètres sélectionnés par GridSearchCV correspondent à la configuration qui maximise ce score, et seront utilisés pour l'évaluation finale sur l'ensemble de test. Cela montre que l'optimisation des hyperparamètres a permis d'améliorer la performance du modèle par rapport à une configuration par défaut.

8) Évaluation

Les modèles de machine learning ont été évalués à l'aide de plusieurs métriques afin d'obtenir une analyse complète de leurs performances. L'accuracy a permis de mesurer la précision globale des prédictions, tandis que la précision, le recall et le F1-score ont permis d'analyser plus finement l'équilibre entre les erreurs de classification. L'AUC-ROC a quantifié la capacité des modèles à distinguer correctement les passagers ayant survécu de ceux n'ayant pas survécu. Les résultats montrent que la régression logistique atteint une accuracy de 0.79, une précision de 0.75, un recall de 0.74, un F1-score de 0.75 et une AUC de 0.87. Le modèle Random Forest obtient une accuracy légèrement supérieure (0.81) et une précision plus élevée (0.82), mais son recall est plus faible (0.69), ce qui indique qu'il identifie moins bien les survivants. Son F1-score est comparable (0.75) et son AUC est légèrement meilleure (0.89), traduisant une meilleure capacité de discrimination globale.

```
Logistic Regression
Accuracy : 0.7932960893854749
Precision : 0.7534246575342466
Recall : 0.7432432432432432
F1 Score : 0.7482993197278912
AUC : 0.8736164736164735
```

```
Random Forest
Accuracy : 0.8100558659217877
Precision : 0.8225806451612904
Recall : 0.6891891891891891
F1 Score : 0.75
AUC : 0.8885456885456886
```

Les matrices de confusion confirment ces tendances : la régression logistique présente un équilibre plus homogène entre faux positifs et faux négatifs (18 FP, 19 FN), tandis que le Random Forest réduit les faux positifs (11 FP) mais augmente les faux négatifs (23 FN), ce qui signifie qu'il prédit mieux les décès mais manque davantage de survivants.

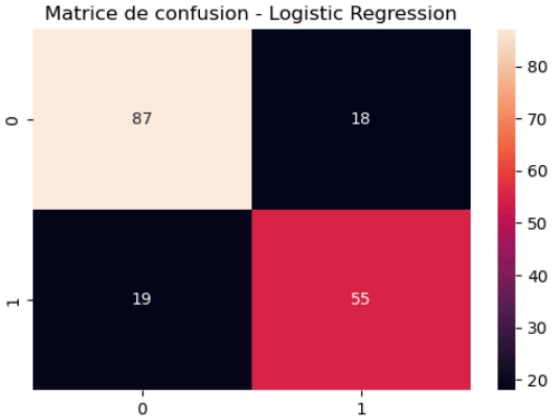

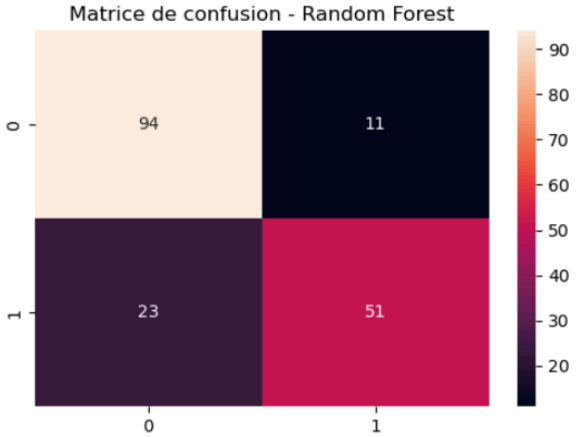

La courbe ROC illustre visuellement cette comparaison : les deux modèles se situent bien au-dessus de la ligne aléatoire, mais la courbe du Random Forest est légèrement plus proche du coin supérieur gauche, confirmant sa meilleure capacité de discrimination.

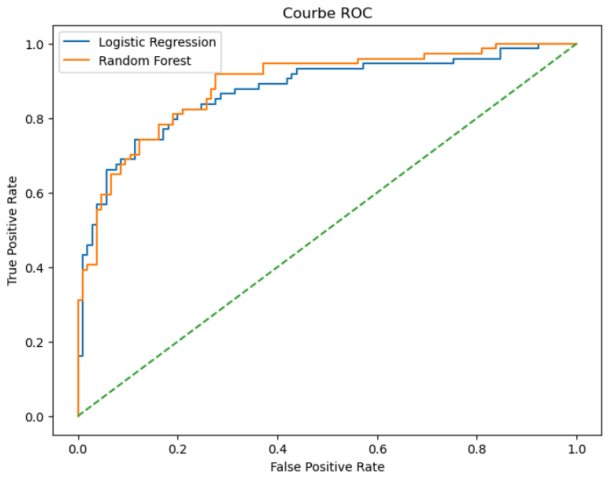

En conclusion, les deux modèles sont performants et complémentaires : la régression logistique offre un meilleur équilibre entre rappel et précision, ce qui est crucial pour identifier correctement les survivants, tandis que le Random Forest capture des relations plus complexes et obtient une meilleure précision et une AUC légèrement supérieure. Sur la base de ces évaluations, le Random Forest peut

être considéré comme le meilleur modèle global, mais la régression logistique reste une alternative robuste et plus interprétable. L'utilisation conjointe ou l'optimisation des hyperparamètres pourrait encore améliorer les performances.